

ER pipeline — vstup: JSON, predčistené dáta

0 — Príprava trénovacích dát

Manuálne anotovanie párov match/no-match. Prípadne augmentácia pomocou CoT distillácie (Mistral/GPT generuje vysvetlenia) pre lepšiu generalizáciu medzi rôznymi pedigree webmi.



1 — voliteľné

Preprocessing

Čistenie surových dát, detekcia near-duplicate datasetov. Pre tvoj prípad nie je potrebné — JSON zo scraperu by mal byť už pripravený. Relevantné ak by sa neskôr pridali nové, neočistené zdroje.



2 — voliteľné

Normalizácia

Zjednotenie formátov mien, skratky plemien, apostrofy, pomlčky. Pre tvoj prípad predpokladáme, že scraper toto rieši. Ak nie, treba zaradiť pred blocking — výrazne ovplyvní jeho kvalitu.



3 — Blocking + block processing

Redukcia kandidátnych párov. Token Blocking alebo Sorted Neighborhood ako prvý filter, Meta-blocking na orezanie neperspektívnych párov. Alternatíva: LSH + bi-encoder (FAISS).



4 — Matching

Rozhodnutie match / no-match pre každý kandidátny pár. Ditto alebo AdapterEM ako primárna metóda, DeepMatcher / Magellan ako baselines pre porovnanie.



5 — Clustering

Zoskupenie párov do klastrov — každý klaster = jedna reálna entita. Connected Components ako základ, Correlation Clustering alebo Markov Clustering pre robustnejšie výsledky.



6 — Evaluácia

Precision, Recall, F1 na testovacej množine. Porovnanie metód in-domain vs cross-domain na manuálne anotovanej vzorke zo skutočných pedigree webov.

Na čo je každá metóda dobrá + v akej fáze

Transformer / LLM metódy

Ditto
Dok. 4

Fáza: Matching

- ✓ Heterogénna schéma
- ✓ Dlhé textové atribúty
- ✓ Malý trénovací set
- ✓ Dirty / zašumené dáta
- ✗ Pomalý na mil. párov

AdapterEM
Dok. 5

Fáza: Matching

- ✓ Low-resource scenáre
- ✓ Viac domén naraz
- ✓ Obmedzená GPU pamäť
- ✓ Rýchle preučenie
- ✗ Mierne nižšia presnosť

CoT distillácia
Dok. 1

Fáza: Tréning / augm.

- ✓ Cross-domain weby
- ✓ Cross-schema
- ✓ Vysvetliteľnosť
- ✗ Generovanie stojí čas
- ✗ Závisí od LLM kvality

Klasické DL baselines

DeepMatcher
Dok. 4, 5

Fáza: Matching

- ✓ Štandardný baseline
- ✓ Rýchlejší ako BERT
- ✗ Slabší na dirty dáta
- ✗ Zlá generalizácia mimo doménu

DeepER
Dok. 4

Fáza: Matching

- ✓ Jednoduchá implement.
- ✓ Referenčný bod
- ✗ Slabší ako transformer metódy vo väčšine scenárov

Near-dup. dataset
Dok. 3

Fáza: Preprocessing

- ✓ Detekcia pred ER
- ✓ Zistí variant webu
- ✓ Rýchle (CatBoost)
- ✗ Neparuje záznamy
- ✗ Iba datasety celkovo

Blocking metódy

Token Blocking
Dok. 2

Fáza: Blocking

- ✓ Schema-agnostic
- ✓ Vysoký recall
- ✗ Veľa false positives
- ✗ Stopwords = obrovské bloky

Meta-blocking
Dok. 2

Fáza: Block processing

- ✓ Precision++ bez straty recallu
- ✓ Schema-agnostic
- ✗ Vyžaduje nastavenie prahu orezania

Sorted Neighborhood
Dok. 2

Fáza: Blocking

- ✓ Robustné voči preklepom v menách
- ✓ Efektívne pre veľké datasety
- ✗ Závisí od kľúča

Clustering metódy

Connected Components
Dok. 2

Fáza: Clustering

- ✓ Jednoduchá implementácia
- ✓ Rýchle
- ✗ Jeden false positive môže reťazovo spojiť nesúvisiace záznamy

Correlation Clustering
Dok. 2

Fáza: Clustering

- ✓ Nevyžaduje počet klastrov dopredu
- ✓ Robustnejšie ako CC
- ✓ Vhodné pre otvorený dataset
- ✗ NP-hard, treba aprox.

Preprocessing

Blocking

Matching

Clustering

Tréning / augmentácia

Rozšírený prehľad metód entity resolution

☐ z dokumentov ☐ doplnené

Preprocessing

☐ Near-dup. dataset Dok. 3

Detekuje či dva celé weby sú variant toho istého zdroja pred ER.
Fáza: Preprocessing

☐ Fellegi-Sunter klasický pravdepod. model Pravdepodobnostný model párovania — každý atribút dostane váhu match / non-match. Základ ER. Fáza: Matching

☐ String similarity Jaro-Winkler, edit distance Jednoduché funkcie na porovnanie mien — Jaro-Winkler dobre funguje na mená so zhodným prefixom. Fáza: Matching

Blocking

☐ Token Blocking Dok. 2

Blok pre každý token. Vysoký recall, nízka presnosť. Prvý hrubý filter.
Fáza: Blocking

☐ Sorted Neighborhood Dok. 2

Abecedné zoradenie + posuvné okno. Robustné voči preklepom v menách mačiek a línií.
Fáza: Blocking

☐ LSH + bi-encoder Sentence-BERT / ANN Embeddingy entít do vektorového priestoru, ANN vyhľadávanie (FAISS) nahrádza klasický blocking. Fáza: Blocking

Block processing

☐ Meta-blocking / BLAST Dok. 2

Váhuje páry podľa zdieľaných blokov, orezáva neperspektívne. Precision++ bez veľkej straty recallu.
Fáza: Block processing

☐ TF-IDF cosine blocking jednoduchá vektorová metóda

TF-IDF reprezentácia atribútov, cosine similarity ako váha párov. Používa ho aj Ditto v sumarizácii.
Fáza: Block processing

Matching

☐ Ditto Dok. 4

Fine-tuning RoBERTa. Heterogénna schéma, DK injection, MixDA. Hlavný kandidát pre pedigree matching.
Fáza: Matching

☐ AdapterEM Dok. 5

Adapter-tuning, ~13% parametrov PrLM. Low-resource, rýchle preučenie na nový pedigree web.
Fáza: Matching

☐ LinkTransformer bi-encoder matching

Sentence-BERT architektúra pre ER — kóduje entity do vektorov, similarity search. Rýchlejší ako cross-encoder (Ditto).
Fáza: Matching

☐ CoT distillácia Dok. 1

LLM generuje vysvetlenia → tréning FlanT5. Cross-domain F1 +10–23%. Vhodné pri rôznych pedigree weboch.
Fáza: Tréning / augm.

☐ PromptEM prompt-tuning pre GEM

Prompt-tuning namiesto fine-tuningu — PrLM zostáva zmrazený, mení sa len prompt. Silné v low-resource scenároch.
Fáza: Matching

☐ Magellan klasický ML systém

Klasické ML — random forest, SVM na ručne definovaných črtách. Dobrý baseline pred DL metódami. Explicitné pravidlá = vysvetliteľný.
Fáza: Matching

Clustering

☐ Connected Components Dok. 2

Tranzitívny uzáver zhôd. Jednoduchý, citlivý na false positives.
Fáza: Clustering

☐ Correlation Clustering Dok. 2

Nevýžaduje počet klastrov dopredu. Vhodné pre otvorený dataset.
Fáza: Clustering

☐ Markov Clustering MCL algoritmus

Náhodné prechádzky v grafe zhôd. Robustné, v experimentoch najlepšie spomedzi clustering metód.
Fáza: Clustering